

UNIVERSIDAD DE COSTA RICA
PROGRAMA DE POSGRADO EN COMPUTACIÓN E INFORMÁTICA

Evaluación integrada de un agente conversacional socrático para programación introductoria

Triangulación de usabilidad, carga cognitiva, comportamiento de interacción, fidelidad
del *prompt* y evidencia cualitativa

Hansell Solís Ramírez

Maestría en Computación e Informática
Junio de 2026

Resumen

Este trabajo evalúa un agente conversacional con andamiaje socrático, diseñado para apoyar el aprendizaje de programación introductoria en la Universidad de Costa Rica (UCR) sin sustituir el razonamiento del estudiante. La evaluación adopta una estrategia de triangulación con cinco fuentes de evidencia recogidas sobre el mismo sistema: usabilidad percibida (System Usability Scale, SUS), carga de trabajo percibida (NASA Task Load Index, NASA-TLX), comportamiento real de interacción (registros de sesión), fidelidad del agente a las reglas de su *prompt* de sistema, y evidencia cualitativa de un *focus group*. Los resultados convergen en un diagnóstico coherente: el agente es operativamente usable (SUS=55,75; grado D) y de carga moderada (NASA-TLX=51,5), con un cuello de botella en el costo de interacción más que en la dificultad conceptual. La carga y la usabilidad correlacionan negativamente de forma significativa ($r=-0,68$; $p=0,03$). El análisis de fidelidad revela que el agente cumple sus reglas esenciales pero se desvió de la prohibición de evaluar en el 35 % de sus respuestas, y que dos de las tres barreras de control previstas en el diseño nunca se implementaron. El *focus group* aporta el umbral de tolerancia a la fricción socrática (3–6 intercambios) y la distinción entre conocimiento declarativo y razonamiento. A partir de la evidencia se propone una versión 2.0 del sistema con trazabilidad explícita entre cada hallazgo y cada cambio.

Palabras clave: tutor socrático, andamiaje pedagógico, modelos de lenguaje, usabilidad, carga cognitiva, triangulación.

Índice

1	Introducción	2
1.1	Aclaración metodológica preliminar	2
2	Marco metodológico	2
2.1	Fuentes de evidencia	2
2.2	Procedimiento de codificación de los registros	2
3	Resultados	3
3.1	Usabilidad percibida (SUS)	3
3.2	Carga cognitiva (NASA-TLX)	3
3.3	Triangulación carga-usabilidad	4
3.4	Comportamiento real de interacción	4
3.4.1	Fiabilidad del servicio	4
3.5	Fidelidad del agente a su <i>prompt</i>	5
3.5.1	Hallazgo de arquitectura: barreras diseñadas no implementadas	5
3.6	Evidencia cualitativa: <i>focus group</i>	5
4	Triangulación integrada	6
4.1	El caso P6: justificación de la triangulación	6
5	Rediseño del sistema (versión 2.0)	6
5.1	Cambios en el <i>prompt</i>	7
5.2	Cambios en la arquitectura	7
6	Discusión	8
7	Limitaciones	8
8	Conclusiones	8

1 Introducción

La irrupción de los modelos de lenguaje de gran escala (LLM) en la educación en programación plantea una tensión documentada: las herramientas que entregan código directamente aceleran a quienes ya saben, pero generan en novatos una “ilusión de competencia” y dependencia cognitiva. El agente evaluado en este trabajo adopta una estrategia opuesta: un andamiaje socrático que guía mediante preguntas y pistas graduales, preservando deliberadamente la fricción cognitiva productiva que la asistencia directa elimina.

Evaluar un sistema de esta naturaleza exige ir más allá de una métrica única. Una alta satisfacción puede esconder un uso mínimo; una carga elevada puede ser señal de aprendizaje o de mero tedio. Por ello, este documento adopta una estrategia de *triangulación* de cinco fuentes complementarias, de modo que cada conclusión quede anclada a evidencia verificable y no a una sola medida. El trabajo responde directamente al objetivo específico 4 (OE4) de la investigación: evaluar la usabilidad y la pertinencia pedagógica del componente conversacional.

1.1 Aclaración metodológica preliminar

A lo largo del documento, la etiqueta “Grupo A / Grupo B” *no* designa dos agentes distintos. El agente evaluado fue el mismo para todos los participantes. La división corresponde a la modalidad de administración del NASA-TLX (escrita para el Grupo A; hablada para el Grupo B, esta última parte de un experimento independiente sobre el instrumento de medición). En consecuencia, el análisis de carga y la triangulación se concentran en el Grupo A ($n=10$), que dispone de ambos instrumentos sobre las mismas personas. Asimismo, el agente operó sobre el modelo *Gemini 2.5 Flash*; las menciones a *Claude Sonnet 4.6* en el *focus group* corresponden únicamente a la herramienta de apoyo para el análisis temático, no al sistema con el que interactuaron los estudiantes.

2 Marco metodológico

2.1 Fuentes de evidencia

La Tabla 1 resume el origen, el objeto de medida y el tamaño muestral de cada fuente.

Cuadro 1. Fuentes de evidencia de la evaluación.

Fuente	Que mide	n
SUS	Usabilidad percibida (0–100)	20 (Grupo A: 10)
NASA-TLX	Carga de trabajo percibida (0–100)	10 (Grupo A)
Registros (<i>logs</i>)	Comportamiento real: turnos, errores, copias, tiempos	20 (24 sesiones)
Fidelidad del <i>prompt</i>	Cumplimiento de las reglas de diseño	374 respuestas
<i>Focus group</i>	Percepción, necesidades y requisitos	5

2.2 Procedimiento de codificación de los registros

Para garantizar reproducibilidad, los 24 archivos de registro se procesaron con un procedimiento determinístico: (1) carga de los archivos; (2) normalización del identificador de participante; (3) separación de eventos por tipo; (4) codificación mediante reglas textuales explícitas; y (5) agregación por participante. Cualquier persona puede repetir el procedimiento sobre los mismos archivos y obtener idénticas cifras. Se reconoce como limitación que la codificación es basada en reglas y no contó con un segundo codificador humano.

3 Resultados

3.1 Usabilidad percibida (SUS)

El puntaje SUS promedio del Grupo A fue 55,75 (DE=14,6), equivalente a un grado D en la escala de Sauro y Lewis y por debajo del promedio de referencia de la industria (68). La Figura 1 muestra la distribución individual. El perfil por ítem (Figura 2) localiza la debilidad: la intención de reuso es el ítem más bajo, seguido de la percepción de inconsistencia y de que el sistema resulta engorroso; la fortaleza es la aprendibilidad, pues ningún participante reportó necesitar apoyo técnico.




Figura 1. Puntaje SUS por participante (Grupo A). Línea roja: promedio del grupo; línea verde: referencia de la industria (68).




Figura 2. Aporte normalizado por ítem (0–4; mayor es mejor). En rojo, los ítems bajo el punto medio.

3.2 Carga cognitiva (NASA-TLX)

La carga global fue moderada (51,5), pero asimétrica. La exigencia física resultó casi nula (12,5), lo que confirma la naturaleza cognitiva de la tarea, mientras que la exigencia temporal fue la única dimensión en nivel alto (71,0). El cuello de botella es, por tanto, temporal: los estudiantes percibieron presión de tiempo.

3.3 Triangulación carga–usabilidad

Como ambos instrumentos se aplicaron a las mismas diez personas, se calculó la correlación de Pearson entre el TLX Raw y el SUS individuales (Figura 3). La relación fue negativa, de magnitud moderada-fuerte y estadísticamente significativa pese al tamaño muestral reducido: $r = -0,68$, $p = 0,03$. A mayor carga percibida, menor usabilidad reportada. Este resultado respalda la validez convergente de ambos instrumentos.




Figura 3. Carga (TLX Raw) frente a usabilidad (SUS) por participante. Recta: tendencia lineal.

3.4 Comportamiento real de interacción

El corpus comprende 411 mensajes de estudiantes y 374 respuestas del agente en 24 sesiones. El uso fue marcadamente heterogéneo (de 3 a 87 turnos por sesión). La clasificación de los mensajes (Figura 4) muestra que el uso dominante fue de apoyo sintáctico y de depuración; que el 70 % de los participantes pegó el enunciado como punto de partida; y que hubo apenas siete peticiones directas de solución, lo que sugiere una aceptación general del encuadre socrático.




Figura 4. Conteo de mensajes por categoría (de 411). Las categorías no son mutuamente excluyentes.

3.4.1 Fiabilidad del servicio

Se registraron 37 fallas técnicas (35 del tipo *Gemini 503*, servicio saturado) que afectaron a 17 de 20 participantes y obligaban a reenviar el mensaje. Estas fallas son ajenas al razonamiento pedagógico del agente, pero contaminan la frustración (NASA-TLX) y la inconsistencia percibida (SUS). Constituyen, por tanto, un confusor que debe aislarse de la fricción pedagógica.

3.5 Fidelidad del agente a su *prompt*

El contraste de las 374 respuestas con las ocho reglas del *prompt* de sistema (Figura 5) arroja un resultado matizado. Las reglas de mantenimiento de rol (R7) y de alcance temático (R8) se cumplieron. La prohibición de no evaluar (R5) fue la desviación más frecuente: 132 respuestas (35 %) contienen algún juicio evaluativo —80 con elogio y 61 con confirmación de corrección, de las cuales 9 presentan ambas formas. La prohibición de no entregar código (R1) se sostuvo en la inmensa mayoría, con 14 fugas concentradas en las sesiones más largas, coincidentes con los fragmentos que dos participantes copiaron. La causa probable de la desviación de R5 es el sesgo del modelo base hacia un registro validante que el *prompt*, por sí solo, no logra suprimir.




Figura 5. Desviaciones medidas sobre las 374 respuestas del agente. La barra de R5 desglosa elogio y juicio de corrección.

3.5.1 Hallazgo de arquitectura: barreras diseñadas no implementadas

El diseño del *prompt* contemplaba, siguiendo a Liffiton et al. (2023), un *pipeline* de tres barreras: verificación de suficiencia (previa), respuesta socrática principal y limpieza de código (posterior). La arquitectura implementada solo ejecutó la barrera central. Las 14 fugas de R1 son la consecuencia directa de la ausencia de la barrera de limpieza, y la regla de andamiaje gradual (R3) resulta no verificable porque la arquitectura no registra el nivel de andamiaje. Este hallazgo reencuadra las debilidades como ingeniería incompleta y no como fallo del enfoque socrático.

3.6 Evidencia cualitativa: *focus group*

Se realizó un *focus group* con cinco estudiantes del Grupo A que habían interactuado con el agente durante el laboratorio. El análisis temático inductivo identificó cinco temas que, de forma independiente, convergen con la evidencia cuantitativa (Figura 6).

Dos aportes resultan especialmente valiosos por no ser observables en las métricas cuantitativas. El primero es el *umbral de tolerancia* a la fricción socrática, estimado por los participantes en tres a seis intercambios, tras los cuales la interacción se vuelve contraproducente, en especial bajo presión de tiempo. El segundo es la distinción entre *conocimiento declarativo* (nombres de funciones, sintaxis exacta) y *razonamiento*: los participantes consideran apropiado el método socrático para el segundo, pero inadecuado e irritante para el primero, pues “nunca se va a adivinar el nombre de una función”. Esta distinción delimita el dominio pedagógicamente legítimo del método.




Figura 6. Convergencia entre los hallazgos del *focus group* y la evidencia cuantitativa o de diseño.

4 Triangulación integrada

La Tabla 2 cruza cada evidencia perceptual con su correlato conductual, de fidelidad o cualitativo. El conjunto dibuja un diagnóstico único y consistente: el valor pedagógico del agente se preserva, pero la experiencia se ve lastrada por factores en buena medida externos a su razonamiento.

Cuadro 2. Matriz de triangulación de fuentes.

Evidencia perceptual	Evidencia conductual/cualitativa	Interpretación integrada
Baja intención de reuso (SUS)	Sesiones largas; 31 señales de atasco; umbral 3–6 (<i>focus group</i>)	Aprendible pero costoso de usar
Inconsistencia percibida (SUS)	37 fallas de servicio; asteriscos ilegibles (<i>focus group</i>)	Parte del malestar es externo al diseño
Exigencia temporal alta (NASA)	Reenvíos por error; “ya dígame la respuesta” (<i>focus group</i>)	La presión sube con la fricción técnica
Frustración (NASA)	R5 evalúa de más; R1 fuga bajo atasco	Andamiaje a veces indirecto, a veces directo de más

4.1 El caso P6: justificación de la triangulación

El participante P6 obtuvo los mejores autorreportes (la menor carga, 31,7, y la mayor usabilidad, 77,5). Una evaluación basada solo en encuestas lo señalaría como el caso de éxito. Sin embargo, los registros muestran que apenas usó el sistema —tres turnos en cinco minutos, antes de que una falla cortara la sesión— (Figura 7). Su valoración positiva refleja exposición mínima, no calidad excepcional. El caso ilustra por qué la triangulación no es un lujo metodológico, sino una salvaguarda contra conclusiones erróneas.

5 Rediseño del sistema (versión 2.0)

Cada cambio propuesto rastrea a una evidencia de las secciones anteriores; ninguno responde a preferencias estéticas. La Tabla 3 resume la trazabilidad.



Figura 7. Exposición (turnos) frente a satisfacción (SUS). El tamaño del punto crece con las fallas de servicio.

Cuadro 3. Trazabilidad de los cambios propuestos.

Problema	Evidencia	Cambio
El agente evalúa de más	R5: 132 respuestas con juicio (35 %)	R5 reforzada (lexico evaluativo prohibido)
Fuga de código bajo atasco	R1: 14 fugas; copias de P2/P7	Barrera 3 de limpieza (no implementada)
Demasiado rígido; no “afloja”	31 atascos; umbral 3–6 (<i>focus group</i>)	Andamiaje en niveles + regla de afloje
Inicios improductivos	27 enunciados pegados	Barrera 1 de suficiencia
No recupera vocabulario técnico	Distinción declarativo/razón. (<i>focus group</i>)	Modo declarativo para nombres/sintaxis
Pregunta lo que el usuario ya sabe	Insight 5 del <i>focus group</i>	Detección/modelado de nivel
Frustración por fallas técnicas	37 errores 503	Reintento con <i>backoff</i>

5.1 Cambios en el *prompt*

Se refuerza R5 enumerando el lexico evaluativo prohibido; se precisa R1 para vedar cualquier fragmento de la solución asignada y canalizar la sintaxis a un problema analogo; y se reescribe R3 con un contador de nivel observable y una “regla de afloje” que, agotado el tercer nivel, ofrece una microacción concreta en lugar de otra pregunta. A partir del *focus group* se añade un *modo declarativo*: el agente distingue una consulta de vocabulario técnico (p.ej., el nombre de un método) de una consulta de razonamiento, y responde directamente la primera, pues negarla es pedagógicamente estéril.

5.2 Cambios en la arquitectura

Se implementan las dos barreras faltantes —verificación de suficiencia y limpieza de código— envolviendo el núcleo socrático, y se registra el nivel de andamiaje como un nuevo evento (`SCAFFOLD_LEVEL`) extrayendo una etiqueta emitida por el modelo. Esto vuelve medible, en el próximo experimento, si el agente escala el andamiaje ante el atasco. Se añade reintento con *backoff* ante el error 503 para mitigar el confusor técnico, y se versiona el *prompt* (v2.0.0) en cada registro, conforme al principio de rendición de cuentas.

6 Discusión

La evidencia converge en que el enfoque socrático cumplió su función esencial: el agente fue aprendible, mantuvo su rol y su alcance, y los estudiantes lo aceptaron con pocas peticiones de solución directa. Las debilidades más relevantes no provienen de la filosofía pedagógica, sino de tres factores acotados: la baja fiabilidad del servicio del modelo base, el sesgo del modelo hacia un registro evaluativo, y la implementación incompleta de las barreras de control previstas en el diseño. La triangulación cuantitativa-cualitativa refuerza esta lectura: los usuarios solicitaron espontáneamente, como requisitos, casi los mismos mecanismos que la evidencia conductual sugería (un techo de fricción configurable y una adaptación al nivel del usuario). Esa coincidencia entre lo que el dato sugiere y lo que el usuario pide constituye un argumento robusto de validez de diseño.

7 Limitaciones

- Tamaño muestral reducido ($n=10$ en el Grupo A; $n=5$ en el *focus group*): los hallazgos orientan el diseño, no se generalizan estadísticamente.
- La codificación de registros es basada en reglas, sin segundo codificador humano; las categorías se solapan.
- La fidelidad se mide solo sobre lo textualmente observable; R3 no es verificable por falta de instrumentación.
- Sesgo de experiencia reciente en el *focus group*: los participantes habían usado el agente bajo presión de tiempo inmediatamente antes.
- Los puntajes SUS dependen de la transcripción de hojas manuscritas, algunas con marcas ambiguas pendientes de verificación.

8 Conclusiones

1. La usabilidad es moderada-baja ($SUS=55,75$) y la carga moderada con pico temporal; ambas convergen en un costo de interacción, no de dificultad conceptual.
2. La correlación carga-usabilidad es significativa ($r=-0,68$; $p=0,03$), lo que valida los instrumentos.
3. El *focus group* aporta el umbral de fricción (3–6) y la distinción declarativo/razonamiento, no observables cuantitativamente.
4. Las debilidades clave son externas o de ingeniería: fallas del proveedor, sesgo del modelo y dos de tres barreras sin implementar.
5. Cada hallazgo se tradujo en un cambio trazable, consolidado en la versión 2.0 del sistema.

Referencias

- [1] Brooke, J. (1996). *SUS: A “quick and dirty” usability scale*. En P. W. Jordan et al. (Eds.), *Usability Evaluation in Industry* (pp. 189–194). Taylor & Francis.
- [2] Hart, S. G., & Staveland, L. E. (1988). Development of NASA-TLX. *Advances in Psychology*, 52, 139–183.
- [3] Sauro, J., & Lewis, J. R. (2016). *Quantifying the User Experience* (2.^o ed.). Morgan Kaufmann.

- [4] Liffiton, M., Sheese, B. E., Savelka, J., & Denny, P. (2023). CodeHelp: Using LLMs with Guardrails for Scalable Support in Programming Classes. *Koli Calling '23*.
- [5] Prather, J. et al. (2024). The Widening Gap: The Benefits and Harms of Generative AI for Novice Programmers. *Proc. ICER '24*.
- [6] Wood, D., Bruner, J. S., & Ross, G. (1976). The role of tutoring in problem solving. *Journal of Child Psychology and Psychiatry*, 17(2), 89–100.